


Previsão de Tendências no Mercado de Criptomoedas



Arthur Barreto e Ulisses Curvello

Motivação

O mercado de criptomoedas é extremamente volátil, com oscilações rápidas e difíceis de prever. Essa instabilidade torna métodos tradicionais pouco eficazes. Nesse contexto, modelos de machine learning se destacam por identificar padrões complexos em séries temporais, permitindo previsões mais robustas e auxiliando na tomada de decisões em um ambiente de alta incerteza.



Objetivo

O objetivo deste trabalho é desenvolver e comparar modelos capazes de prever o comportamento futuro do Bitcoin a partir de seus dados históricos. A análise é dividida em duas perspectivas complementares: prever o valor numérico do preço no próximo dia e identificar se esse preço tende a subir ou não. Para isso, são exploradas duas abordagens distintas: regressão, que busca estimar diretamente o valor futuro da criptomoeda, e classificação, que determina a direção do movimento com base nas variações observadas.

Qual abordagem de modelagem deve ser usada para prever o comportamento do Bitcoin?



Dataset Utilizado

Dataset : Cryptocurrency Historical Prices

O conjunto de dados utilizado foi obtido na plataforma Kaggle e contém registros históricos de preço e volume do Bitcoin. O dataset inclui variáveis como preço de abertura (**OPEN**), preço de fechamento (**CLOSE**), maior e menor valor do dia (**HIGH e LOW**), volume negociado (**VOLUME**) e valor de mercado (**MARKETCAP**). A série abrange um período contínuo de vários anos, permitindo observar ciclos completos de alta e baixa do mercado. Esses dados fornecem uma base sólida para análise, pré-processamento e construção dos modelos de previsão abordados neste trabalho.





Gráfico das Features



Análise Exploratória

A análise exploratória mostrou forte assimetria nas variáveis de preço e volume, além da presença de outliers devido à alta volatilidade do mercado. Para reduzir essas distorções, foram aplicadas **transformação log1p** e **normalização StandartScaler**. A matriz de correlação também revelou alta dependência entre os preços, indicando que essas variáveis carregam informações redundantes — algo comum em séries financeiras.




Figura 3: Matriz de correlação entre as variáveis


Divisão Treino/Teste

A divisão entre treino e teste foi realizada seguindo a proporção de 80% para treino e 20% para teste, respeitando integralmente a ordem temporal da série. Essa decisão é fundamental em problemas de previsão financeira, pois evita que o modelo tenha acesso a informações do futuro durante o treinamento, o que configuraria vazamento de dados e geraria métricas artificialmente infladas. Ao manter o conjunto de teste como o bloco final da linha do tempo, garante-se que a avaliação reflita um cenário realista de predição, no qual o modelo é confrontado apenas com dados jamais vistos e que representam de fato períodos posteriores aos usados no ajuste inicial.



Treino

Utiliza 80% dos dados para
ajuste do modelo



Teste

Avalia o modelo com 20%
dos dados jamais vistos


Modelos Utilizados

Para Regressão


- Regressão Linear
- LSTM (Long Short Term Memory)

Para Classificação


- Random Forest
- XGBoost (Extreme Gradient Boost)



Resultados do LSTM



Resultados da Regressão Linear



Comparando os dois modelos

Tabela 1: Resultados da Regressão Linear (Baseline)

Métrica	MAE	RMSE	R ²
Valor	\$712.08	\$1,311.12	0.99

Tabela 2: Resultados do Modelo LSTM

Métrica	MAE	RMSE	R ²
Valor	\$2,250.43	\$3,979.16	0.95

A comparação entre Regressão Linear e LSTM foi feita usando três métricas de avaliação.

MAE (Erro Médio Absoluto): mede o erro médio, em dólares, entre o valor previsto e o real. Quanto menor, melhor. A Regressão Linear obteve MAE de \$712.08, enquanto o LSTM teve \$2,250.43, mostrando que o LSTM erra, em média, muito mais por previsão.

RMSE (Raiz do Erro Quadrático Médio): semelhante ao MAE, mas penaliza mais os erros grandes. A Regressão Linear alcançou \$1,311.12, bem abaixo dos \$3,979.16 do LSTM, indicando que o LSTM sofre mais com previsões muito distantes do real.

R² (Coeficiente de Determinação): indica quanto da variação dos dados o modelo consegue explicar. A Regressão Linear obteve 0.99, enquanto o LSTM chegou a 0.95. Ambos explicam bem os padrões do preço, mas a Regressão Linear apresenta leve vantagem.

No geral, a Regressão Linear superou o LSTM em todas as métricas, entregando previsões mais estáveis e precisas.

Resultados da classificação

Previsão para 1 dia: Ambos os modelos apresentaram desempenho próximo ao aleatório, com acurácia em torno de 50%. Random Forest teve leve vantagem (50.9% vs 49.1%), mas os resultados indicam grande dificuldade em prever movimentos de curtíssimo prazo.

Previsão para 30 dias: XGBoost superou ligeiramente o Random Forest (53.4% vs 52.3% de acurácia). Ambos mostraram alta precisão (~80%), mas baixo recall (~28%), comportando-se de forma conservadora ao prever altas apenas com forte confiança.

Conclusões principais:

- Prever Bitcoin é extremamente desafiador, com acurácias próximas ao acaso;
- Horizontes maiores permitem maior precisão, mas detectam menos oportunidades;
- As diferenças entre Random Forest e XGBoost são marginais;
- A engenharia de features é mais importante que a escolha do algoritmo.

Resultados da classificação

Previsão para 1 dia:

Modelo	Acurácia	Precisão	Recall	F1-score	CV Accuracy
Random Forest	0.509182	0.554167	0.415625	0.475000	0.486800
XGBoost	0.490818	0.531646	0.393750	0.452424	0.490477

Previsão para 30 dias:

Modelo	Acurácia	Precisão	Recall	F1-score	CV Accuracy
Random Forest	0.522538	0.798387	0.275000	0.409091	0.479116
XGBoost	0.534224	0.818898	0.288889	0.427105	0.487773

Conclusões

A análise comparativa demonstrou que a **Regressão Linear** apresentou o melhor desempenho no horizonte de previsão estudado, superando a **LSTM** tanto em aderência quanto em erro médio absoluto. Para classificação, o **XGBoost** mostrou-se mais consistente e robusto, oferecendo melhor qualidade dos sinais binários em relação ao **Random Forest**. Verificou-se também que o pré-processamento, especialmente o uso de **log1p** aliado à **normalização**, foi determinante para estabilizar a escala e melhorar o comportamento dos modelos. De forma geral, a tarefa de prever movimentos de curto prazo favoreceu métodos mais simples e diretamente guiados pelos padrões lineares presentes na série.



OBRIGADO!

Referências

- **Scikit-learn. Machine Learning in Python. Disponível em: <https://scikit-learn.org/stable/>. Acesso em: 20 nov. 2025.**
- **Kaggle. Cryptocurrency Historical Market Price Dataset – Sudalai Rajkumar. Disponível em: <https://www.kaggle.com/datasets/sudalairajkumar/cryptocurrencypricehistory>. Acesso em: 20 nov. 2025.**
- **GeeksforGeeks. Introduction to Long Short-Term Memory (LSTM). Disponível em: <https://www.geeksforgeeks.org/deep-learning/deep-learning-introduction-to-long-short-term-memory/>. Acesso em: 20 nov. 2025.**