




Universidade Federal Do Paraná

Aprendizado de Máquina para Previsão de Tendências no Mercado de Criptomoedas

Arthur Barreto Godoi | arthur.godoi@ufpr.br

Ulisses Curvello Ferreira | ulissesferreira@ufpr.br

Curitiba, 22 de novembro de 2025

Disciplina: CI1171 Aprendizado De Máquina

Professora: Aurora Trinidad Ramirez Pozo

Sumário

1	Introdução	2
2	Tipo de Previsão	2
2.1	Previsão por Regressão	2
2.2	Previsão por Classificação	3
3	Features Criadas	3
4	Pré-processamento e Engenharia de Dados	6
4.1	Limpeza e Ordenação	7
4.2	Transformação e Normalização (Regressão)	7
4.3	Preparação de Sequências para LSTM	7
5	Divisão Treino/Teste em Séries Temporais	7
6	Treinamento e Modelos	9
6.1	Modelos utilizados na Regressão	9
6.2	Modelos utilizados na Classificação	9
7	Avaliação	10
7.1	Regressão	10
7.1.1	LSTM: Atual vs Previsto	10
7.1.2	Regressão Linear: Atual vs Previsto	10
7.1.3	LSTM Loss (MAE)	11
7.2	Classificação	13
7.2.1	Curva ROC - Comparação entre Horizontes Temporais	13
7.2.2	Importância das Features - Evolução com o Horizonte Temporal . .	14
7.2.3	Matrizes de Confusão - Padrões de Erro entre Horizontes	14
8	Conclusão	15

1. Introdução

O mercado de criptomoedas é conhecido por sua alta volatilidade, comportamento não linear e forte dependência de fatores externos. Esses elementos tornam a previsão de preços e tendências um desafio relevante dentro da área de aprendizado de máquina.

O objetivo deste trabalho foi investigar diferentes técnicas de machine learning aplicadas ao **Bitcoin**, utilizando dados históricos de preços e volume. Foram implementados dois tipos de previsão:

Regressão: para prever o valor de fechamento do dia seguinte.

Classificação: para determinar se o preço irá subir ou cair no próximo dia.

Utilizamos métodos tradicionais, como **Regressão Linear** e **Random Forest**, além de modelos mais avançados, como **LSTM** e **XGBoost**, comparando seu desempenho em diferentes métricas.

Link para o dataset: [Kaggle \(Cryptocurrency Historical Prices\)](#)

2. Tipo de Previsão

O presente estudo detalha o processo de modelagem e previsão de preços do Bitcoin. A análise metodológica aborda duas perspectivas fundamentais em *Machine Learning* financeiro: a **Regressão**, que visa estimar o valor numérico exato do preço futuro, e a **Classificação**, focada em prever a simples direção do movimento de preço (subida ou descida). Serão apresentadas as decisões cruciais de pré-processamento, bem como a arquitetura dos modelos utilizados.

2.1. Previsão por Regressão

O modelo tenta estimar um valor numérico contínuo, focado na previsão do **Preço de fechamento (Close)** do dia seguinte. Esta abordagem é inerentemente mais detalhada, buscando a acurácia no valor absoluto da criptomoeda, o que a torna indispensável para **análise de investimento** e **backtesting** de estratégias que dependem de preços específicos (como ordens de *limit order* ou *stop-loss*). Modelos de regressão, como o LSTM e a Regressão Linear, avaliam a magnitude da mudança e o erro de previsão em termos monetários (MAE e RMSE), fornecendo suporte crítico à **tomada de decisão quantitativa** que exige uma estimativa de preço, e não apenas a direção do mercado.

2.2. Previsão por Classificação

Aqui, o objetivo muda de estimar um valor para prever a **direção** do movimento de preço, resumindo o complexo comportamento do mercado em um sinal binário: **1 (preço sobe)** ou **0 (preço não sobe)**. Esta simplificação é extremamente útil para **sistemas de trading automatizado** e estratégias de curto prazo, pois o foco está na decisão operacional de **compra ou venda** (ou manutenção), independentemente da exata magnitude da mudança. A natureza do problema é intrinsecamente mais desafiadora, e a avaliação foca em métricas como Precisão e *Recall*, que medem a qualidade dos sinais de compra (acurácia dos "1"s previstos), sendo o resultado crucial para a construção de um **sinal simples** de trading.

3. Features Criadas

O projeto baseou-se nas *features* intrínsecas do *dataset* de Bitcoin, incluindo o **Preço de Abertura (*Open*)**, Preço Máximo (*High*), Preço Mínimo (*Low*), o **Volume** negociado e o **Marketcap** (valor de mercado). A partir dessas colunas, foram criadas as variáveis *target* necessárias para as duas abordagens: o *target* de **regressão** (preço de fechamento do dia seguinte, obtido por deslocamento $\rightarrow \text{Close}_{t+1}$) e o *target* de **classificação** (uma variável binária que indica se o preço subiu (1) ou não (0)). Antes da modelagem, um rigoroso processo de **Análise Exploratória de Dados (AED)** foi conduzido para garantir a qualidade e o entendimento das variáveis. Este processo incluiu a geração de **histogramas** e *KDE plots* para observar a distribuição e a assimetria (*skewness*) dos dados; *boxplots* para identificação e visualização de *outliers*; e uma **matriz de correlação** para quantificar e visualizar as relações lineares entre todas as *features* numéricas.




Figura 1: Histograma de todas as Features

Os histogramas revelam que todas as features do Bitcoin (High, Low, Open, Close, Volume, Marketcap) apresentam uma distribuição altamente assimétrica com cauda longa à direita, onde a grande maioria dos dados históricos (1400 dias) está concentrada em valores baixos (abaixo de \$5,000), enquanto apenas alguns períodos pontuais apresentam valores extremamente altos (acima de \$60,000), caracterizando o comportamento exponencial do ativo. Esta assimetria extrema justifica tecnicamente a aplicação de transformações logarítmicas ($\log_{1p}$) seguidas de padronização (StandardScaler) no código, pois sem esse tratamento os modelos de machine learning teriam dificuldade em aprender padrões devido à variância instável, dominância de outliers e diferenças de escala entre features (Volume em 10^{11} vs preços em 10^4), o que resultaria em previsões imprecisas e convergência lenta dos algoritmos LSTM e de regressão linear.




Figura 2: Os gráficos de densidade kernel (KDE) confirmam a distribuição assimétrica de todas as *features*, com alta concentração de valores próximos a zero e caudas longas à direita, evidenciando o comportamento exponencial do Bitcoin e a necessidade de transformações logarítmicas para normalização dos dados.




Figura 3: Matriz de correlação entre as variáveis

A matriz de correlação apresenta os coeficientes de Pearson entre as variáveis numéricas, revelando uma correlação quase perfeita (1.00) entre as variáveis de preço (*High*, *Low*, *Open*, *Close*) e *Marketcap*, o que é esperado, pois representam diferentes aspectos do mesmo fenômeno, embora essa multicolinearidade possa ser problemática para alguns modelos, como a regressão linear. Em contraste, a variável *Volume* apresenta correlação moderada (0.80–0.81) com as variáveis de preço, sugerindo que, apesar da tendência de aumento do volume em períodos de preços altos, essa relação não é perfeitamente linear. Assim, o *Volume* contém informação complementar independente, tornando-o uma feature valiosa que introduz uma dimensão adicional sobre a atividade e liquidez do mercado não capturada apenas pelos preços.

4. Pré-processamento e Engenharia de Dados

O pré-processamento aplicado foi fundamental para assegurar que os modelos de *Machine Learning* recebessem **dados padronizados, limpos e otimizados** para o aprendizado de padrões sequenciais.

4.1. Limpeza e Ordenação

A primeira etapa concentrou-se na limpeza estrutural do *dataset*. Foram removidas as colunas identificadoras (*SNo*, *Name*, *Symbol*) por não possuírem valor preditivo. Em seguida, a coluna *Date* foi convertida para o formato *datetime* e o *dataset* foi **ordenado cronologicamente**, garantindo a integridade da série temporal. Foi verificada a ausência de valores nulos ou duplicados, garantindo a qualidade inicial dos dados.

4.2. Transformação e Normalização (Regressão)

Para a modelagem de regressão, foram aplicadas duas transformações essenciais:

- **Transformação Logarítmica ($\log_{10}$)**: Aplicada tanto nas *features* quanto no *target*, esta técnica mitigou a **assimetria** e o impacto de valores extremos (*outliers*), fenômenos comuns em dados financeiros, resultando em uma distribuição de dados mais próxima da normal.
- **Normalização (*StandardScaler*)**: Utilizando o *StandardScaler*, as variáveis foram padronizadas com média zero e desvio padrão unitário. Esta etapa é crucial para modelos sensíveis à escala, como a **LSTM** e a Regressão Linear, pois assegura que o treinamento baseado em gradiente não seja dominado por *features* com maior magnitude.

4.3. Preparação de Sequências para LSTM

Exclusivamente para o modelo **LSTM**, os dados de treino e teste (já normalizados) foram transformados em **janelas temporais** de 60 dias. Essa conversão é necessária para estruturar os dados em um formato que a rede neural recorrente possa processar, permitindo que ela aprenda a dependência entre o histórico de 60 dias de *features* e o preço a ser previsto no dia subsequente.

5. Divisão Treino/Teste em Séries Temporais

A metodologia de divisão dos dados foi crucialmente planejada para o contexto de séries temporais, adotando a seguinte proporção:

- 80% dos dados para treino;

- 20% para teste.

Esta divisão foi executada **sem embaralhamento**, preservando rigorosamente **a ordem temporal** (treinar com os dados mais antigos e testar com os mais recentes). Essa abordagem é obrigatória para simular fielmente o uso real do modelo (utilizar o passado para prever o futuro) e, principalmente, para **evitar o vazamento de informação** (*data leakage*). O *data leakage* ocorreria se dados futuros (pertencentes ao conjunto de teste) fossem inadvertidamente incluídos no treino, resultando em métricas de desempenho artificialmente elevadas e um modelo que falharia miseravelmente ao ser implementado no mundo real. A divisão temporal garante que a avaliação, em particular para modelos sequenciais como o **LSTM**, seja uma medida honesta e confiável da capacidade preditiva do modelo sobre dados temporais nunca antes vistos.

6. Treinamento e Modelos

6.1. Modelos utilizados na Regressão

A abordagem de regressão iniciou com a **Regressão Linear** como *baseline*. Este modelo, sendo simples e rápido, estabeleceu a **linha de base** de desempenho, permitindo avaliar se os modelos mais complexos realmente justificavam seu custo computacional com melhorias significativas nas métricas. O modelo principal para a previsão de valores contínuos foi a rede neural **LSTM** (*Long Short-Term Memory*). Como um modelo avançado baseado em redes recorrentes, a LSTM é capaz de capturar **dependências temporais de longo prazo** na série de preços. Sua arquitetura foi configurada com **50 unidades** na camada LSTM, utilizando o **Otimizador Adam** e a **Função de Perda MAE** (*Mean Absolute Error*). Foi implementado o **Early Stopping** para monitorar a perda na validação e interromper o treinamento, restaurando os melhores pesos, para prevenir o *overfitting*.

6.2. Modelos utilizados na Classificação

Para a tarefa de classificação binária (previsão da direção do preço), foram selecionados dois modelos de *ensemble* robustos. O **Random Forest** é um algoritmo baseado na combinação de múltiplas árvores de decisão. Sua natureza de *ensemble* permite lidar eficazmente com **não linearidades** e o torna relativamente **robusto a outliers**. O segundo modelo escolhido foi o **XGBoost** (*Extreme Gradient Boosting*), um algoritmo de *boosting* conhecido por sua **alta capacidade preditiva** e eficiência. Ambos os modelos foram treinados com os **parâmetros ajustados manualmente** (incluindo número de estimadores e profundidade máxima) para otimizar o desempenho na previsão da direção do mercado.

7. Avaliação

7.1. Regressão

7.1.1. *LSTM: Atual vs Previsto*

O gráfico revela que o modelo LSTM captura bem a tendência geral dos preços do Bitcoin, com sobreposição quase perfeita entre valores reais (azul) e previsões (laranja) nas primeiras 300 observações (5.000–20.000 dólares). Entretanto, a partir do ponto 300, quando os preços disparam até 64.000 dólares, observa-se uma defasagem sistemática crescente: o modelo subestima consistentemente os valores reais em períodos de alta volatilidade, com *gaps* de 10.000 a 15.000 dólares nas regiões de máximos (pontos 400–480). Essa discrepância explica o MAE relativamente alto de \$2,250,43, indicando que, apesar de capturar bem a direção e a tendência, o modelo tem dificuldade em prever a magnitude exata dos movimentos extremos característicos do mercado de criptomoedas.




Figura 4: LSTM: Atual vs Previsto

7.1.2. *Regressão Linear: Atual vs Previsto*

A Regressão Linear apresenta desempenho surpreendentemente superior ao LSTM, com sobreposição quase perfeita entre valores reais (azul) e previsões (laranja) ao longo de toda a série temporal, incluindo os períodos de alta volatilidade e o pico próximo a 64.000 dólares. Essa aderência excepcional se traduz nas métricas reportadas (MAE de

\$712,08 e R^2 de 0,99), sugerindo que a relação linear entre as features disponíveis e o preço do dia seguinte é suficientemente forte para previsões precisas.

Este resultado aparentemente contraintuitivo ocorre porque prever o preço do próximo dia usando informações do dia atual é essencialmente uma tarefa de interpolação de curtíssimo prazo, onde a inércia do mercado e a alta correlação entre dias consecutivos favorecem modelos lineares, enquanto a vantagem do LSTM em capturar dependências de longo prazo não se materializa plenamente neste horizonte imediato.




Figura 5: Regressão Linear: Atual vs Previsto

7.1.3. *LSTM Loss (MAE)*

O gráfico de evolução da perda durante o treinamento revela convergência saudável, mas com sinais de overfitting moderado. A curva de treino (azul) cai rapidamente de 0,145 para abaixo de 0,05 na época 2, estabilizando-se em torno de 0,03. Já a curva de validação (laranja) apresenta comportamento mais irregular: após uma queda inicial, continua diminuindo de forma oscilatória até a época 15 (aproximadamente 0,05), após o qual começa a apresentar flutuações e leve aumento, atingindo cerca de 0,08 na época 20.

Essa divergência caracteriza um caso de overfitting leve, no qual o modelo passa a memorizar padrões específicos do conjunto de treino que não se generalizam perfeitamente para os dados de validação. O mecanismo de *Early Stopping* foi crucial para interromper o treinamento no momento ideal e restaurar os pesos correspondentes à melhor época de validação, evitando degradação da capacidade de generalização.




Figura 6: Gráfico de evolução da perda

Tabela 1: Resultados da Regressão Linear (Baseline)

Métrica	MAE	RMSE	R ²
Valor	\$712.08	\$1,311.12	0.99

Tabela 2: Resultados do Modelo LSTM

Métrica	MAE	RMSE	R ²
Valor	\$2,250.43	\$3,979.16	0.95

7.2. Classificação

Primeiro fizemos a classificação para o dia seguinte

Tabela 3: Comparação de Modelos de Classificação para 1 dia

Modelo	Acurácia	Precisão	Recall	F1-score	CV Accuracy
Random Forest	0.509182	0.554167	0.415625	0.475000	0.486800
XGBoost	0.490818	0.531646	0.393750	0.452424	0.490477

Tabela 4: Comparação de Modelos de Classificação para 30 dias

Modelo	Acurácia	Precisão	Recall	F1-score	CV Accuracy
Random Forest	0.522538	0.798387	0.275000	0.409091	0.479116
XGBoost	0.534224	0.818898	0.288889	0.427105	0.487773

7.2.1. Curva ROC - Comparação entre Horizontes Temporais

A comparação das Curvas ROC revela diferença significativa na capacidade preditiva conforme o horizonte temporal. Na previsão de 1 dia, ambos os modelos apresentam desempenho praticamente aleatório (AUC de 0.506 e 0.507), com curvas que mal se distinguem da diagonal cinza. Em contraste, a previsão de 30 dias demonstra melhoria substancial (AUC de 0.589 e 0.592), com curvas se afastando claramente da diagonal, especialmente na região de FPR entre 0.0–0.4. Essa evolução indica que padrões de médio prazo são mais capturáveis, pois a volatilidade de curtíssimo prazo é parcialmente suavizada em horizontes mais longos, permitindo que tendências estruturais se manifestem de forma mais previsível.




Figura 7: Dois gráficos lado a lado

7.2.2. Importância das Features - Evolução com o Horizonte Temporal

A análise revela mudança fundamental nas prioridades dos modelos entre horizontes. Para 1 dia, o Random Forest identifica *Open* como a feature mais importante (0.20), enquanto o XGBoost prioriza *Volume* (0.22). Contudo, todas as features apresentam importâncias similares (0.16–0.22), indicando contribuição equilibrada. Para 30 dias, o Random Forest atribui dominância ao *Volume* (~ 0.25), enquanto o XGBoost mantém *Low* como principal (~ 0.22). Essa transição revela que, em horizontes longos, padrões de liquidez e atividade acumulada tornam-se mais informativos que preços de abertura instantâneos, sugerindo que a dinâmica de médio prazo é mais influenciada por fluxos de capital agregado, explicando a melhoria no AUC.




Figura 8: Dois gráficos lado a lado

7.2.3. Matrizes de Confusão - Padrões de Erro entre Horizontes

As matrizes revelam transformação nos padrões de erro entre horizontes. Para 1 dia, ambos os modelos exibem erros equilibrados (Random Forest: 107 falsos positivos e

133 falsos negativos; XGBoost: 111 e 126), resultando em acurácia de aproximadamente 50–55%, próxima ao acaso. Para 30 dias, emerge uma assimetria pronunciada: o Random Forest apresenta apenas 25 falsos positivos, mas 99 falsos negativos (razão $\sim 1:4$), enquanto o XGBoost apresenta 23 e 104. Essa assimetria indica viés para classificar como subida, possivelmente refletindo a tendência ascendente histórica do Bitcoin. Apesar desse viés, a acurácia melhora para cerca de 58–60%, confirmando que a tarefa de prever 30 dias é mais tratável.




Figura 9: Dois gráficos lado a lado

8. Conclusão

Neste trabalho, testamos diferentes modelos para prever o preço do Bitcoin e vimos que, mesmo sendo um método simples, a Regressão Linear foi o modelo que teve o melhor desempenho. Isso aconteceu porque o preço do Bitcoin muda de forma relativamente previsível de um dia para o outro, o que favorece modelos lineares.

A LSTM, que é um modelo mais avançado e próprio para séries temporais, não apresentou resultados melhores neste caso. Ela teve mais dificuldade para lidar com momentos de forte variação no preço e acabou errando mais. Os gráficos de perda mostraram até sinais de overfitting, indicando que ela precisaria de mais ajustes ou mais dados para melhorar.

De modo geral, o estudo mostrou que nem sempre o modelo mais complexo é o melhor. Dependendo do tipo de dado e do tipo de previsão, modelos simples podem funcionar muito bem. Para melhorar no futuro, seria interessante testar mais variáveis, aumentar a janela temporal ou usar modelos mais modernos, como Transformers ou combinações de diferentes técnicas.

Referências

- [1] Scikit-learn. *Machine Learning in Python*. Disponível em: <https://scikit-learn.org/stable/>. Acesso em: 20 nov. 2025.
- [2] Kaggle. *Cryptocurrency Historical Market Price Dataset – Sudalai Rajkumar*. Disponível em: <https://www.kaggle.com/datasets/sudalairajkumar/cryptocurrencypricehistory>. Acesso em: 20 nov. 2025.
- [3] GeeksforGeeks. *Introduction to Long Short-Term Memory (LSTM)*. Disponível em: <https://www.geeksforgeeks.org/deep-learning/deep-learning-introduction-to-long-short-term-memory/>. Acesso em: 20 nov. 2025.