

Classificação de Sentimentos em Análises de Filmes

Utilizando BERT

Pedro Henrique Gurski de Oliveira

Ulisses Curvello Ferreira

Etapas para o desenvolvimento

1

Dataset Utilizado

Identificação do objetivo: classificar sentimentos (positivo/negativo) em análises de filmes.

2

Arquitetura do Modelo

Seleção do modelo base: BERT-base-uncased.
Definição dos hiperparâmetros (batch size, épocas, learning rate).

3

Validação Cruzada e Execução dos Experimentos

Validação cruzada com 3 folds para garantir robustez.

Armazenamento de métricas por fold (accuracy, precision, recall, F1).

4

Análise e Interpretação dos Resultados

Comparação direta entre os dois experimentos.

Análise detalhada de matrizes de confusão.

Discussão sobre as melhorias obtidas e os desafios enfrentados.

PROBLEMA DATASET - IMDB


O objetivo deste trabalho foi desenvolver um classificador capaz de determinar se uma análise de filme possui sentimento positivo ou negativo.

Esta tarefa de classificação binária é fundamental para compreender a opinião dos usuários sobre produtos cinematográficos.

Características do dataset:

- Tamanho original: 50.000 análises
- Amostras utilizadas: 5.000 (Experimento 1) e 6.500 (Experimento 2) análises
- Classes: Positivo (1) e Negativo (0)
- Distribuição: Balanceada (50% para cada classe)
- Tipo de texto: Análises de filmes em inglês de tamanho variável


Arquitetura do Modelo - BERT



Modelo base: bert-base-uncased (12 camadas, 768 dimensões)




Comprimento máximo: 128 tokens



Tokenizer: BertTokenizer do Hugging Face




3-Fold



Exp. 1: 3.333 exemplos para treino e 1.667 para validação por fold.

Exp. 2: 4.333 exemplos para treino e 2.167 para validação por fold.




Métricas: Accuracy, Precision, Recall e F1-Score

Parâmetros Utilizados

Parâmetro	Experimento 1	Experimento 2
Épocas	1	2
Batch size (treino)	4	16
Batch size (validação)	4	32
Tamanho da amostra	5.000	6.500
Otimizador	AdamW (padrão)	AdamW (padrão)
Learning rate	5e-5 (padrão)	5e-5 (padrão)
Seed	42	42
Device	CUDA	CUDA


Matrizes Confusão - Experimento 1

FOLD-1




Verdadeiros Negativos: 697
Falsos Positivos: 156
Falsos Negativos: 102
Verdadeiros Positivos: 712
Taxa de Erro: 15.48%

FOLD-2



Verdadeiros Negativos: 601
Falsos Positivos: 190
Falsos Negativos: 94
Verdadeiros Positivos: 782
Taxa de Erro: 17.04%


FOLD-3



Verdadeiros Negativos: 629
Falsos Positivos: 208
Falsos Negativos: 127
Verdadeiros Positivos: 702
Taxa de Erro: 20.11%


Matrizes Confusão - Experimento 2

FOLD-1




Verdadeiros Negativos: 872
Falsos Positivos: 200
Falsos Negativos: 97
Verdadeiros Positivos: 998
Taxa de Erro: 13.71%

FOLD-2



Verdadeiros Negativos: 948
Falsos Positivos: 136
Falsos Negativos: 132
Verdadeiros Positivos: 951
Taxa de Erro: 12.37%

FOLD-3



Verdadeiros Negativos: 920
Falsos Positivos: 144
Falsos Negativos: 147
Verdadeiros Positivos: 955
Taxa de Erro: 13.43%

Análise Comparativa de Resultados

Experimento 1

Fold	Accuracy	Precision	Recall	F1-Score
Fold 1	0.8452	0.8203	0.8747	0.8466
Fold 2	0.8296	0.8045	0.8927	0.8463
Fold 3	0.7989	0.7714	0.8468	0.8074
Média	0.8246	0.7987	0.8714	0.8334
Desvio Padrão	±0.0192	±0.0204	±0.0189	±0.0184

Experimento 2

Fold	Accuracy	Precision	Recall	F1-Score
Fold 1	0.8629	0.8331	0.9114	0.8705
Fold 2	0.8763	0.8749	0.8781	0.8765
Fold 3	0.8657	0.8690	0.8666	0.8678
Média	0.8683	0.8590	0.8854	0.8716
Desvio Padrão	±0.0058	±0.0185	±0.0190	±0.0036

Comparação:

Experimento	Accuracy	Precision	Recall	F1-Score
Exp. 1 (5k, 1 época)	0.8246 ± 0.0192	0.7987 ± 0.0204	0.8714 ± 0.0189	0.8334 ± 0.0184
Exp. 2 (6.5k, 2 épocas)	0.8683 ± 0.0058	0.8590 ± 0.0185	0.8854 ± 0.0190	0.8716 ± 0.0036
Melhoria	+4.37%	+6.03%	+1.40%	+3.82%

Analizando Resultados

Tempo: 5h 30min (Experimento 1) e 12h 40min (Experimento 2).

Experimento 1: Recall alto (87.14%) mas precision mais baixa (79.87%)

Experimento 2: Melhor balanceamento entre recall (88.54%) e precision (85.90%)

Mais dados (6.5k vs 5k): Contribuiu para melhor generalização

Mais épocas (2 vs 1): Permitiu convergência mais completa

Batch size maior: Melhorou a estabilidade do treinamento

Training loss: Demonstrou convergência adequada sem overfitting

Desafios enfrentados e Melhorias

- Incompatibilidade entre versões de Bibliotecas
- Interrupções recorrentes no Google Colab após muito tempo de uso



- Uso de sequências mais longas (até 512 tokens)
- Treinamento com todo o Dataset (50k)
- Learning Rate diferente do utilizado
- Estratégias de regularização como dropout e weight decay



Obrigado!