

Classificação Utilizando Redes Neurais Multicamadas

Trabalho I - Tópicos em Aprendizado de Máquina

Ulisses Curvello Ferreira — GRR: 20223829

Pedro Henrique Gurski de Oliveira — GRR: 20224759

Universidade Federal do Paraná

Abril 2025

Sumário

1	Introdução	3
2	Descrição dos Datasets	3
2.1	Titanic	3
2.2	Student Depression	4
2.3	Car Evaluation	5
3	Exploração e Pré-processamento	6
4	Arquitetura da Rede	6
5	Resultados obtidos	7
6	Conclusão	8

1 Introdução

Neste relatório, desenvolvemos modelos de redes neurais do tipo *Multi-Layer Perceptron* (MLP) utilizando a biblioteca PyTorch, com o objetivo de resolver tarefas de classificação supervisionada. Para isso, exploramos três conjuntos de dados públicos: **Titanic - Machine Learning from Disaster**, **Student Depression** e **Car Evaluation**.

2 Descrição dos Datasets

2.1 Titanic

O naufrágio do Titanic é um dos naufrágios mais infames da história.

Em 15 de abril de 1912, durante sua viagem inaugural, o RMS Titanic, considerado "inafundável", afundou após colidir com um iceberg. Infelizmente, não havia botes salvavidas suficientes para todos a bordo, resultando na morte de 1.502 dos 2.224 passageiros e tripulantes.

Embora houvesse algum elemento de sorte envolvido na sobrevivência, parece que alguns grupos de pessoas tinham mais probabilidade de sobreviver do que outros.

Neste dataset queremos saber que tipos de pessoas tinham mais probabilidade de sobreviver, usando dados de passageiros (ou seja, nome, idade, sexo, classe socioeconômica, etc.).

Utilizamos colunas específicas do Dataset(colunas como nome ou número do bilhete não foram utilizadas por não terem dados suficientes ou serem irrelevantes):

- **Pclass**: Classe de ingresso;
- **Sexo**;
- **Idade**;
- **SibSp**: Irmãos/cônjuges a bordo do Titanic;
- **Parch**: Pais/filhos a bordo do Titanic;
- **Fare**: Tarifa de passageiro;
- **Embarked**: Embarcou;
- **Sobreviveu**.

Link Dataset: <https://www.kaggle.com/competitions/titanic/data>

2.2 Student Depression

O conjunto de dados sobre depressão apresenta uma visão dos elementos que possivelmente afetam o bem-estar mental dos alunos, se concentra especialmente na identificação da depressão. Esta análise de dados oferece um valor significativo para psiquiatras, cientistas de dados e profissionais da educação, visando aprimorar a compreensão das origens da depressão em estudantes e possibilitar o desenvolvimento de abordagens de intervenção para casos detectados precocemente.

Este conjunto de dados abrange informações sobre diversos elementos que influenciam os estudantes, como a cidade onde moram, seu desempenho e seus hábitos cotidianos. Cada entrada no conjunto de dados representa um estudante diferente, com as variáveis reunidas retratando tanto sua condição física quanto emocional.

- **ID:** Um identificador único.
- **Gênero:** Masculino, feminino ou outro.
- **Idade:** A idade do estudante.
- **Cidade:** A cidade ou região de residência.
- **Profissão:** Trabalho ou estudo do estudante, que pode ajudar a identificar fontes de estresse ocupacional.
- **Pressão Acadêmica:** Incluindo estresse devido a exames, tarefas e expectativas acadêmicas gerais.
- **Pressão no Trabalho:** Indica o nível de pressão relacionado ao trabalho.
- **CGPA:** O rendimento acadêmico.
- **Satisfação com os Estudos:** Grau de satisfação estudante.
- **Satisfação no Trabalho:** Satisfação com o emprego.
- **Duração do Sono:** Número médio de horas de sono por dia.
- **Hábitos Alimentares:** Avaliação dos padrões alimentares do estudante.
- **Curso ou Grau Acadêmico:** O tipo de graduação ou programa acadêmico.
- **Pensamentos Suicidas:** Indicador binário (Sim/Não) que revela se o estudante já teve pensamentos suicidas.
- **Horas de Trabalho/Estudo:** Número médio de horas por dia dedicadas ao trabalho ou ao estudo.
- **Estresse Financeiro:** Medida do estresse relacionado a preocupações financeiras.
- **Histórico Familiar de Doenças Mentais:** Indicação de um histórico familiar.
- **Depressão** A variável-alvo indica se o aluno está sofrendo de depressão (Sim/Não). Este é o foco principal da análise.

Link Dataset: <https://www.kaggle.com/datasets/adilshamim8/student-depression-dataset>

2.3 Car Evaluation

O banco de dados de avaliação de carros foi derivado de um modelo de decisão hierárquico simples desenvolvido originalmente para a demonstração de DEX, M. Bohanec, V. Rajkovic: Sistema especialista para tomada de decisão. Sistemica 1(1), pp. 145-157, 1990.).

O modelo avalia carros de acordo com a seguinte estrutura conceitual:

- **Compra:** Preço de compra;
- **Manutenção:** Preço da manutenção;
- **Portas:** Número de portas;
- **Pessoas:** Capacidade em termos de pessoas para transportar;
- **Porta-malas:** Tamanho do porta-malas;
- **Segurança:** Segurança estimada do carro;
- **Alvo:** unacc(não aceitável), acc(aceitável), good(bom), v-good(muito bom).

Link Dataset: <https://www.kaggle.com/datasets/elikplim/car-evaluation-dataset>

ou: <https://archive.ics.uci.edu/dataset/19/car+evaluation>

3 Exploração e Pré-processamento

Para a preparação dos dados, foi seguida uma rotina onde os demais datasets também poderiam se beneficiar. Fizemos o uso de bibliotecas como `pandas`, `numpy`, `matplotlib`. O primeiro conjunto de dados foi o Titanic, proveniente da plataforma Kaggle.

Em um primeiro momento, foram removidas colunas que não trazem informações úteis para o modelo ou colunas com alta cardinalidade, como `id`, que não têm tanta relevância analítica e como as colunas `Ticket` e `Cabin`. Estas foram removidas para gerar um treinamento mais limpo, assim, usando somente colunas que realmente têm uma importância alta para a decidibilidade. Em seguida, realizamos os tratamentos dos valores ausentes e, para colunas categóricas, o valor ausente foi preenchido com a moda dos demais valores da coluna, enquanto que, para colunas numéricas, utilizamos a mediana para minimizar valores outliers.

Último passo as variáveis categóricas foram transformadas em valores numéricos por meio do `LabelEncoder`, permitindo que fossem exploradas pela rede neural. Os dados também foram padronizados com o `StandardScaler`, garantindo que todas as variáveis tivessem média 0 e desvio padrão 1, o que é essencial para um treinamento estável.

Para a base de dados do Depressão Estudantil, segue uma abordagem muito semelhante à do Titanic. Inicialmente, removemos colunas de baixa relevância, como o `id`. Em seguida, tratamos os valores ausentes e, depois, padronizamos os dados com o auxílio do `LabelEncoder` para variáveis categóricas e, por fim, padronizamos os dados com o `StandardScaler`, garantindo a média de 0 e desvio padrão de 1.

Para o dataset dos Carros, a primeira coisa que fazemos é identificar a coluna de alvo, ou seja, qual coluna será usada como critério para o treinamento. Não houve necessidade de remover colunas, dado que todas são úteis para o treinamento da rede neural. Os valores ausentes foram tratados de forma análoga aos outros dois datasets e padronizados também de forma análoga aos outros dois conjuntos de dados.

- Tratamento de valores ausentes com moda ou mediana;
- Codificação de variáveis categóricas com `LabelEncoder`;
- Padronização dos dados com `StandardScaler`.

4 Arquitetura da Rede

A arquitetura de rede neural é do tipo perceptron multicamadas (Multilayer Perceptron – MLP), implementada com a biblioteca `PyTorch`. A rede tem 3 camadas ocultas de 64 neurônios, intercaladas com a função de ativação `ReLU` (Rectified Linear Unit). A camada de saída da rede tem 10 unidades, o que representa o número máximo de classes possíveis no problema, embora esse número possa ser ajustado conforme a necessidade de cada dataset.

A arquitetura da MLP implementada foi:

- Camada de entrada: número de atributos do dataset.

- Três camadas ocultas com 64 neurônios e ativação ReLU.
- Camada de saída com número de classes (ajustável).
- Acurácia;
- Precisão (weighted);
- Recall (weighted);
- F1-score (weighted).

5 Resultados obtidos

Após 5 rodadas de validação cruzada, os resultados médios foram:

Métrica	Acurácia	Precisão	Recall	F1-score
Titanic	0.8193	0.8233	0.8193	0.8128
Depressão	0.8453	0.8449	0.8453	0.8448
Carro	0.9218	0.9085	0.9218	0.9093

A seguir, analisamos individualmente os resultados para cada conjunto de dados, detalhando cada métrica:

Titanic

- **Acurácia (0.82):** O modelo classificou corretamente 82% dos passageiros.
- **Precisão (0.82):** Entre os classificados como sobreviventes, 82% realmente sobreviveram.
- **Recall (0.82):** O modelo identificou corretamente 82% dos passageiros que realmente sobreviveram.
- **F1-score (0.81):** Mostra que o modelo tem um bom equilíbrio entre precisão e recall.

Depressão

- **Acurácia (0.84):** O modelo acertou a classe correta para 84% dos alunos.
- **Precisão (0.84):** 84% dos alunos classificados como depressivos realmente apresentavam depressão.
- **Recall (0.84):** O modelo identificou corretamente 84% dos casos reais de depressão.
- **F1-score (0.84):** Reflete uma consistência excelente entre precisão e recall.

Car Evaluation

- **Acurácia (0.92)**: O modelo classificou corretamente 92% dos carros.
- **Precisão (0.90)**: 90% das classificações de classe foram corretas.
- **Recall (0.92)**: 92% dos exemplos foram corretamente atribuídos às suas classes.
- **F1-score (0.90)**: Confirma o ótimo desempenho geral, com equilíbrio entre precisão e recall.

Por o Dataset Carro ser desbalanceado, unacc (70.023 %), acc (22.222 %), good (3.993 %) e v-good (3.762 %) — pode ser enganosa se o modelo apenas “chutar” a classe majoritária.

6 Conclusão

A aplicação de MLPs para tarefas de classificação mostrou resultados promissores. A metodologia adotada provou ser eficaz em generalizar e avaliar modelos de forma robusta via validação cruzada, é interessante testar com novos datasets maiores e mais equilibrados.

Além disso, o uso de múltiplos datasets com características distintas possibilitou testar a flexibilidade das redes neurais MLP. Os resultados obtidos reforçam o potencial das MLPs como uma abordagem viável e eficiente para tarefas de classificação. Com base na metodologia aplicada, este estudo fornece uma base sólida para experimentações futuras com arquiteturas mais complexas e conjuntos de dados mais desafiadores.

Desafios enfrentados

- Dificuldade ao encontrar modelos viáveis para o modelo;
- Identificar melhorias dos datasets para um melhor desempenho;
- Descobrir melhor forma para se treinar os modelos;
- Desequilíbrio entre classes em alguns datasets.
- Escolha da arquitetura ideal para diferentes tipos de dados.

Melhorias futuras

- Datasets mais robustos e tratamento exclusivo;
- Batch Normalization;
- Explorar outras funções de ativação(LeakyReLU, GELU, SiLU ...);
- Early Stopping;
- Implementar técnicas de regularização (Dropout, L2).
- Ajustar learning rate e tamanho dos batches.
- Testar outras arquiteturas (CNN, RNN) e ensembles.